

# LLM’lerin Ağ Anomali Loglarını MITRE ATT&CK ile Eşleştirme Kapasitesinin Karşılaştırmalı Değerlendirmesi

**Öğrenci:** Mervenur Güman **Ders:** BGK601 — Bilgi Güvenliği Alanında Makine Öğrenmesi Yöntemleri **Dönem:** Bahar 2025–2026 **Teslim Tarihi:** 14 Mayıs 2026

---

## Özet

SOC ekipleri her gün binlerce log satırını incelemek zorunda kalır. Bu yük, analist hatalarını artırır ve kritik tehditlerin gözden kaçmasına zemin hazırlar. LLM’lerin bu süreçte ne ölçüde güvenilir sonuçlar üretebileceği ise hâlâ net değildir.

Bu çalışmada, altı farklı LLM konfigürasyonu CICIDS2017 veri seti üzerinden oluşturulan 360 örneklik bir benchmark ile test edilmiştir. Modeller; saldırı tespiti, MITRE ATT&CK taktik/teknik sınıflandırması görevlerinde karşılaştırılmıştır.

En dikkat çekici bulgu, kapalı ve açık kaynak modeller arasındaki performans farkıdır. Claude Sonnet 4.5 %84 saldırı tespit doğruluğuyla en iyi sonucu alırken, Llama 3.2 ve Mistral 7B RAG desteği olmaksızın anlamlı bir tespit yapamamıştır. RAG sistemi devreye alındığında ise Mistral’ın başarısı %15’ten %57’ye çıkmıştır.

Öte yandan tüm modellerde MITRE ATT&CK teknik eşleştirme doğruluğunun %0 ile %6.4 arasında kaldığı görülmüştür. Bu sonuç, mevcut LLM’lerin saldırıyı tespit edebilse de onu doğru sınıflandırmakta zorlandığını ortaya koymaktadır. Dolayısıyla bu sistemler şu an için bir karar verici değil; SOC analistini destekleyen bir yardımcı araç olarak konumlandırılmalıdır.

---

## 1. Giriş ve Motivasyon

Ağ güvenliği operasyonlarında log analizi, tehdit tespitinin temel bileşenlerinden birini oluşturmaktadır. SOC analistleri bu süreci büyük ölçüde kural tabanlı SIEM sistemleriyle yürütmektedir; ancak bu sistemler yeni saldırı varyantları ve düşük yoğunluklu anomaliler karşısında yetersiz kalmaktadır.

LLM’lerin kod analizi, zafiyet tespiti ve tehdit istihbaratı özetleme gibi görevlerde umut verici sonuçlar verdiği bildirilmektedir [1, 2]. Bununla birlikte, ham ağ trafiği istatistiklerini yorumlama ve MITRE ATT&CK çerçevesiyle eşleştirme konusundaki performansları henüz sistematik biçimde ölçülmemiştir.

Bu çalışmada iki kapalı kaynak (Claude Sonnet 4.5, GPT-5.4-mini) ve iki açık kaynak (Llama 3.2, Mistral 7B) model; 360 örneklik bir benchmark üzerinde karşılaştırmalı olarak değerlendirilmiştir.

RAG tekniğinin açık kaynak model performansına katkısı da ablasyon çalışmasıyla ölçülmüştür.

---

## 2. İlgili Çalışmalar

### 2.1 Siber Güvenlikte LLM Uygulamaları

LLM'lerin siber güvenlik alanındaki uygulamaları son yıllarda araştırmacıların ilgisini çekmektedir. IDS loglarından MITRE ATT&CK tekniklerinin çıkarımına odaklanan bir çalışmada, Suricata uyarıları üzerinde LLM tabanlı bir çerçeve denenmiş ve modellerin paket düzeyindeki veriden saldırgan niyetine ilişkin çıkarımlar yapabildiği görülmüştür [3]. Benzer bir yaklaşımla tehdit istihbaratı raporlarından ATT&CK teknik tespiti için farklı Llama 2 konfigürasyonları değerlendirilmiş; az sayıda etiketli örnek ve sınıf dengesizliğinin model başarısını ciddi ölçüde kısıtladığı tespit edilmiştir [4]. CVE açıklamalarının ATT&CK tekniklerine otomatik olarak eşleştirilmesini ele alan bir diğer çalışmada ise GPT-4o-mini ile Llama 3.3-70B karşılaştırılmış; kapalı kaynak modelin bu görevde belirgin biçimde öne çıktığı raporlanmıştır [5].

### 2.2 RAG ve Siber Güvenlik Uygulamaları

Retrieval-Augmented Generation tekniği bilgi yoğun NLP görevleri için önerilmiş [6] ve siber güvenlik uygulamalarında da kullanılmaya başlanmıştır. Llama-3-8B modeline hibrit RAG uygulandığında LLM doğruluğunun ve zamansal akıl yürütme kapasitesinin iyileştiği gösterilmiştir [7]. Ağ saldırısı tespiti alanında önerilen bir RAG tabanlı IDS çerçevesinde, bilgi tabanından alınan bağlamın analist raporu kalitesini BERTScore ve ROUGE metrikleri açısından artırdığı bildirilmiştir [8]. Çok adımlı yeniden değerlendirme mekanizmasıyla saldırı sınıflandırmasını güçlendiren ajansal bir RAG mimarisi de önerilmiştir [9].

### 2.3 Ağ Saldırısı Tespiti ve Veri Setleri

CICFlowMeter ile elde edilen 80'den fazla ağ trafiği özelliğini içeren CICIDS2017, IDS araştırmalarında yaygın biçimde kullanılan etiketli bir veri setidir [1]. MITRE ATT&CK çerçevesinin araştırma literatüründeki uygulamalarını ele alan bir derleme çalışmasında 417 yayın incelenerek tehdit tespiti ve olay müdahalesi alanlarındaki kullanım örüntüleri ortaya konmuştur [11].

### 2.4 Büyük Dil Modelleri

Llama 2, yalnızca kamuya açık veri setleriyle eğitilerek rekabetçi sonuçlar elde edilebileceğini ortaya koyan açık kaynaklı bir model ailesidir [12]. Mistral 7B, grouped-query attention ve sliding window attention mekanizmalarıyla Llama 2 13B'yi çeşitli kıyaslamalarda geride bırakmaktadır [13]. GPT-4

teknik raporu ise büyük ölçekli modellerin çok adımlı akıl yürütme görevlerindeki yeteneklerini kapsamlı biçimde belgelemektedir [14].

## 2.5 Bu Çalışmanın Konumlandırılması

Yukarıda incelenen çalışmaların büyük çoğunluğu metin tabanlı girdiler üzerinde çalışmaktadır: CTI raporları, alert metinleri veya zafiyet açıklamaları. Bu çalışmada ham sayısal ağ trafiği istatistikleri girdi olarak kullanılmakta; kapalı kaynak ve açık kaynak modeller aynı benchmark üzerinde, RAG ablasyonunu da kapsayacak biçimde karşılaştırmalı olarak değerlendirilmektedir.

## 3. Yöntem

### 3.1 Genel Pipeline Tasarımı

Çalışmada Splunk tabanlı bir ön işleme katmanı üzerinde LLM değerlendirmesi gerçekleştirilmiştir. Genel akış şu şekildedir: CICIDS2017 veri seti Splunk'a indexlenerek ham CSV kayıtları sorgulanabilir hale getirilmiş, ardından seçilen özellikler Python pipeline'ı aracılığıyla LLM'e iletilmiş ve model çıktıları ground-truth ile karşılaştırılmıştır.




Figure 1: Splunk Benchmark Dashboard

### 3.2 Veri Seti ve Benchmark Oluşturma

**Veri kaynağı:** CICIDS2017 veri seti, University of New Brunswick tarafından oluşturulmuş ve gerçek bir ağ ortamında hem benign hem de saldırı trafiğini içeren etiketli bir kaynaktır [1]. CICFlowMeter ile üretilen 80'den fazla özellik arasından LLM girdi temsili için 11 özellik seçilmiştir: Destination

Port, Flow Duration, Total Fwd/Bwd Packets, Flow Bytes/s, Flow Packets/s, SYN/RST/FIN Flag Count, Fwd/Bwd Packet Length Mean.

**Benchmark tasarımı:** 4 kategori ve 9 alt kategori kapsamında 360 örnek seçilmiştir. Her kategoriden örnekler Easy/Medium/Hard olarak eşit dağılımla etiketlenmiştir.

| Kategori          | Alt Kategoriler                                                | N          |
|-------------------|----------------------------------------------------------------|------------|
| Reconnaissance    | PortScan                                                       | 40         |
| Credential Access | FTP-Patator, SSH-Patator                                       | 80         |
| DoS/DDoS          | DDoS, DoS Hulk, DoS GoldenEye, DoS slowloris, DoS Slowhttptest | 200        |
| Benign            | BENIGN                                                         | 40         |
| <b>Toplam</b>     |                                                                | <b>360</b> |

**Anotasyon:** CICIDS2017 sınıf etiketleri, MITRE ATT&CK Enterprise framework'ü (v14) ile araştırmacı tarafından manuel olarak eşleştirilmiştir.

| CICIDS Etiketi   | ATT&CK Tactic     | Technique ID |
|------------------|-------------------|--------------|
| PortScan         | Discovery         | T1046        |
| FTP-Patator      | Credential Access | T1110.001    |
| SSH-Patator      | Credential Access | T1110.001    |
| DDoS             | Impact            | T1498        |
| DoS Hulk         | Impact            | T1499        |
| DoS GoldenEye    | Impact            | T1499        |
| DoS slowloris    | Impact            | T1499        |
| DoS Slowhttptest | Impact            | T1499        |
| BENIGN           | —                 | —            |

### 3.3 Model Konfigürasyonları

| Model             | Tür           | Versiyon          | Ortam          |
|-------------------|---------------|-------------------|----------------|
| Claude Sonnet 4.5 | Kapalı kaynak | claude-sonnet-4-5 | Anthropic API  |
| GPT-5.4-mini      | Kapalı kaynak | gpt-5.4-mini      | OpenAI API     |
| Llama 3.2         | Açık kaynak   | llama3.2 (3B)     | Ollama (yerel) |
| Mistral 7B        | Açık kaynak   | mistral:latest    | Ollama (yerel) |

| Model            | Tür               | Versiyon       | Ortam          |
|------------------|-------------------|----------------|----------------|
| Llama 3.2 + RAG  | Açık kaynak + RAG | llama3.2 (3B)  | Ollama (yerel) |
| Mistral 7B + RAG | Açık kaynak + RAG | mistral:latest | Ollama (yerel) |

Tüm modellere aynı prompt şablonu uygulanmıştır. System prompt'ta SOC analist rolü tanımlanmış ve JSON formatında çıktı istenmiştir. User prompt'ta ise her örneğe ait 11 özellik sayısal olarak sunulmuştur. Tüm deneylerde temperature=0 olarak sabitlenmiş, deterministik çıktı hedeflenmiştir. Bununla birlikte API kaynaklı küçük varyasyonlara karşı her örnek 3 bağımsız çalıştırma ile test edilmiş; sonuçlar bu çalıştırmaların ortalaması olarak raporlanmıştır.

### 3.4 RAG Sistemi

RAG sistemi, açık kaynak modellerin alan bilgisi eksikliğini gidermek amacıyla kurulmuştur. MITRE ATT&CK Enterprise JSON dosyası LangChain ile 500 karakterlik örtüşen parçalara ayrılmış, sentence-transformers kütüphanesinin all-MiniLM-L6-v2 modeli [10] ile vektörleştirilmiş ve ChromaDB'ye kaydedilmiştir. Çalışma zamanında her örnek için cosine similarity aramasıyla en ilgili 3 ATT&CK tekniği alınmış ve prompt'a bağlam olarak eklenmiştir.

### 3.5 Değerlendirme Protokolü

| Metrik              | Ölçüm Yöntemi               | Ağırlık |
|---------------------|-----------------------------|---------|
| Attack Detection    | Ground-truth exact match    | %25     |
| Tactic Accuracy     | Exact match                 | %25     |
| Technique Accuracy  | Exact match (ID)            | %20     |
| JSON Parse Başarısı | Parse oranı                 | %10     |
| Açıklama Kalitesi   | İnsan değerlendirmesi (1–5) | %10     |
| Gecikme             | Ortalama ms                 | %5      |
| Maliyet             | \$/örnek                    | %5      |

İstatistiksel güvenilirlik için %95 bootstrap güven aralıkları hesaplanmış; kapalı kaynak modeller arasındaki performans farkının anlamlılığı McNemar testi ile sınanmıştır.

Gecikme skoru en hızlı modeli (GPT-5.4-mini, 1.62s) referans olarak normalize edilmiştir:  $gecikme\_skoru = 1.62 / model\_latency$ . Maliyet skoru üç kademeli olarak belirlenmiştir: ücretsiz

yerel modeller 1.0, GPT-5.4-mini 0.7, Claude Sonnet 4.5 0.4. Açıklama kalitesi her model için 20 örnek üzerinde araştırmacı tarafından 1–5 arası puanlanmış ve 5’e bölünerek normalize edilmiştir.

### 3.6 Fine-Tuning (LoRA/QLoRA)

Llama 3.2 modeline LoRA (Low-Rank Adaptation) ile alan odaklı ince ayar uygulanmıştır. CIDS2017 veri setinden benchmark ile örtüşmeyen 540 örnek seçilerek eğitim seti oluşturulmuştur. Eğitim Google Colab T4 GPU ortamında Unsloth kütüphanesi kullanılarak gerçekleştirilmiştir.[16]

| Parametre              | Değer                 |
|------------------------|-----------------------|
| Temel model            | Llama 3.2 3B Instruct |
| LoRA rank (r)          | 16                    |
| Eğitilebilir parametre | 24.3M (%0.75)         |
| Epoch                  | 3                     |
| Eğitim örneği          | 540                   |
| Eğitim süresi          | 518 saniye            |
| Başlangıç loss         | 2.22                  |
| Final loss             | 0.23                  |

## 4. Sonuçlar

### 4.1 Genel Model Performansı

| Model             | Attack % | Tactic % | Technique % | Ağırlıklı Skor | Latency |
|-------------------|----------|----------|-------------|----------------|---------|
| Claude Sonnet 4.5 | 84.0     | 6.8      | 6.4         | 44.8           | 6.09s   |
| GPT-5.4-mini      | 45.2     | 8.5      | 2.2         | 37.8           | 1.62s   |
| Mistral 7B + RAG  | 57.5     | 2.8      | 0.0         | 34.6           | 75.9s   |
| Llama 3.2 + RAG   | 38.3     | 6.1      | 0.6         | 27.4           | 13.8s   |
| Mistral 7B (base) | 15.3     | 0.0      | 0.0         | 21.9           | 23.5s   |
| Llama 3.2 (base)  | 11.1     | 0.0      | 0.0         | 20.5           | 10.6s   |

*Ağırlıklı skor: Attack (%25), Tactic (%25), Technique (%20), JSON Parse (%10), Açıklama Kalitesi (%10), Gecikme (%5), Maliyet (%5) metriklerinin toplamıdır. Açıklama kalitesi 20 örnek üzerinde insan değerlendirmesiyle (1–5) ölçülmüştür.*

Saldırı tespiti için precision, recall ve F1 skorları aşağıda verilmektedir.




Figure 2: Model Karşılaştırması — Tüm Metrikler




Figure 3: Model Karşılaştırması — Attack Detection

| Model             | Precision | Recall | F1    |
|-------------------|-----------|--------|-------|
| Claude Sonnet 4.5 | 0.964     | 0.841  | 0.898 |
| GPT-5.4-mini      | 0.942     | 0.409  | 0.571 |
| Mistral 7B + RAG  | 0.849     | 0.634  | 0.726 |
| Llama 3.2 + RAG   | 0.799     | 0.409  | 0.541 |
| Mistral 7B (base) | 1.000     | 0.047  | 0.090 |
| Llama 3.2 (base)  | 0.000     | 0.000  | 0.000 |

Mistral 7B (base) precision=1.0 ile nadiren saldırı etiketi üretmekte ancak ürettiğinde doğru yapmaktadır. Llama 3.2 (base) ise hiçbir örneği saldırı olarak etiketlemediğinden F1=0 elde edilmiştir. Claude Sonnet 4.5 hem precision hem recall açısından dengeli ve en yüksek F1 skorunu elde etmiştir.

BERTScore hesaplanmamıştır; açıklama kalitesi ground-truth referans açıklama bulunmadığından insan değerlendirmesiyle (1–5) ölçülmüştür.

#### 4.2 Bootstrap Güven Aralıkları

| Model                   | Attack % | %95 CI       |
|-------------------------|----------|--------------|
| Claude Sonnet 4.5       | 84.0     | [81.7, 86.1] |
| GPT-5.4-mini            | 45.2     | [42.0, 48.2] |
| Mistral 7B + RAG        | 57.5     | [54.7, 60.6] |
| Llama 3.2 + RAG         | 38.3     | [35.5, 41.5] |
| Mistral 7B (base)       | 15.3     | [13.2, 17.5] |
| Llama 3.2 (base)        | 11.1     | [9.3, 13.0]  |
| Llama 3.2 + Fine-tuning | 88.9     | [82.2, 94.4] |

#### 4.3 İstatistiksel Anlamlılık

Claude Sonnet 4.5 ile GPT-5.4-mini arasında McNemar testi uygulanmış; b=149, c=13 değerleriyle ki-kare=112.5,  $p<0.0001$  elde edilmiştir. Bu sonuç, iki model arasındaki performans farkının istatistiksel olarak anlamlı olduğunu ortaya koymaktadır.

#### 4.4 RAG Ablasyon Analizi

| Model      | Base % | RAG % | Artış    |
|------------|--------|-------|----------|
| Llama 3.2  | 11.1   | 38.3  | +27.2 pp |
| Mistral 7B | 15.3   | 57.5  | +42.2 pp |



| Model | Base % | RAG % | Artış |
|-------|--------|-------|-------|
|-------|--------|-------|-------|




Figure 4: RAG Ablasyon Analizi

#### 4.5 Kategori Bazlı Hata Analizi

#### 4.5 Kategori Bazlı Hata Analizi

| Kategori         | Claude | GPT | Mistral+RAG | Llama+RAG | Mistral | Llama |
|------------------|--------|-----|-------------|-----------|---------|-------|
| PortScan         | 62%    | 57% | 75%         | 85%       | 0%      | 0%    |
| FTP-Patator      | 100%   | 50% | 98%         | 75%       | 38%     | 0%    |
| SSH-Patator      | 92%    | 25% | 5%          | 48%       | 0%      | 0%    |
| DDoS             | 100%   | 35% | 92%         | 12%       | 0%      | 0%    |
| DoS Hulk         | 70%    | 22% | 80%         | 18%       | 0%      | 0%    |
| DoS GoldenEye    | 62%    | 25% | 68%         | 0%        | 0%      | 0%    |
| DoS slowloris    | 92%    | 45% | 57%         | 15%       | 0%      | 0%    |
| DoS Slowhttptest | 92%    | 68% | 32%         | 75%       | 0%      | 0%    |
| BENIGN           | 75%    | 80% | 10%         | 18%       | 100%    | 100%  |

#### 4.6 Nitel Analiz

Her model için 20 örnek üzerinde açıklama kalitesi araştırmacı tarafından 1–5 arası puanlandırılmıştır.

| Model             | Açıklama Kalitesi |
|-------------------|-------------------|
| Claude Sonnet 4.5 | 3.75/5            |
| GPT-5.4-mini      | 2.70/5            |
| Mistral 7B + RAG  | 2.21/5            |
| Llama 3.2 + RAG   | 1.65/5            |
| Mistral 7B (base) | 1.35/5            |
| Llama 3.2 (base)  | 1.00/5            |

#### 4.7 Maliyet-Başarım Analizi

Mistral 7B + RAG kombinasyonu, sıfır API maliyetiyle %57.5 attack detection doğruluğuna ulaşarak en iyi maliyet-başarım dengesini sunmaktadır. Bütçe kısıtı olmayan senaryolarda Claude Sonnet 4.5 tercih edilmeli; maliyet öncelikliyse Mistral 7B + RAG güçlü bir alternatif oluşturmaktadır.




Figure 5: Maliyet-Başarım Dengesi

#### 4.8 Fine-Tuning Sonuçları

Llama 3.2 modeline LoRA ile uygulanan alan odaklı ince ayarın sonuçları aşağıdaki tabloda sunulmaktadır.

| Model            | Attack % | Tactic % | Technique % | Ağ. Skor | %95 CI       |
|------------------|----------|----------|-------------|----------|--------------|
| Llama 3.2 (base) | 11.1     | 0.0      | 0.0         | 20.5     | [9.3, 13.0]  |
| Llama 3.2 + RAG  | 38.3     | 6.1      | 0.6         | 27.4     | [35.5, 41.5] |

| Model                   | Attack % | Tactic % | Technique % | Ağ. Skor | %95 CI       |
|-------------------------|----------|----------|-------------|----------|--------------|
| Llama 3.2 + Fine-tuning | 88.9     | 88.9     | 77.8        | 83.8     | [82.2, 94.4] |

Değerlendirme, benchmark veri setinin tamamından (360 örnek) her kategoriden 10 örnek rastgele seçilmesiyle oluşturulan 90 örneklik bir alt küme üzerinde yapılmıştır (random.seed=99). Bu örnekler fine-tuning eğitim setiyle (540 örnek, random.seed=123) örtüşmemektedir.

Fine-tuning, attack detection doğruluğunu %11'den %89'a, tactic accuracy'yi %0'dan %89'a, technique accuracy'yi ise %0'dan %78'e yükseltmiştir. Bu üç metrikte de RAG konfigürasyonunu belirgin biçimde geride bırakmıştır.

Eğitim süreci boyunca loss değerinin 2.22'den 0.23'e düşmesi modelin eğitim verisini başarıyla öğrendiğini göstermektedir. 204 adımda tamamlanan eğitim yaklaşık 518 saniye sürmüştür; bu süre T4 GPU ortamında LoRA'nın hesaplama verimliliğini ortaya koymaktadır.

Kategori bazlı incelemede PortScan, FTP-Patator, SSH-Patator, DDoS ve tüm DoS kategorilerinde %100 başarı elde edilmiştir. Ancak BENIGN sınıfında 0/10 başarı dikkat çekmektedir. Model her örneği saldırı olarak etiketleme eğilimi göstermiş; bu durum eğitim setindeki sınıf dengesizliğinden kaynaklanmaktadır. 540 eğitim örneğinin 480'i saldırı, yalnızca 60'ı BENIGN sınıfına aittir.

Fine-tuning ve RAG yaklaşımları farklı güçlü yönler sergilemektedir. RAG, modele dışarıdan bilgi sağlayarak attack detection doğruluğunu artırırken; fine-tuning modelin iç parametrelerini güncelleyerek hem saldırı tespiti hem de ATT&CK sınıflandırmasında çok daha güçlü sonuçlar üretmektedir. Bununla birlikte fine-tuning, eğitim verisi gerektirmesi ve BENIGN sınıfındaki başarısızlık gibi kısıtlamalar barındırmaktadır.

Fine-tuned modelin %95 bootstrap güven aralığı [82.2%, 94.4%] olarak hesaplanmıştır. Dar güven aralığı, 90 örneklik test setinde elde edilen %88.9 attack detection doğruluğunun güvenilir bir tahmin olduğuna işaret etmektedir.

## 5. Tartışma

### 5.1 Kapalı ve Açık Kaynak Modeller

Elde edilen bulgular, kapalı kaynak modellerin bu görevde açık kaynak alternatiflere kıyasla belirgin biçimde daha iyi performans sergilediğini ortaya koymaktadır. Claude Sonnet 4.5'in %84 attack detection doğruluğuna ulaşması, büyük ölçekli modellerin ağ trafiği yorumlama kapasitesinin göz ardı edilemeyeceğini göstermektedir. Bununla birlikte tactic ve technique doğruluğunun tüm modellerde düşük kalması, yüksek genel dil kapasitesinin alan özgü yapılandırılmış çıktı üretimini otomatik olarak garanti etmediğine işaret etmektedir.

GPT-5.4-mini'nin attack detection açısından Claude'un gerisinde kalması, ancak tactic accuracy açısından en yüksek skoru elde etmesi ilgi çekicidir. Bu durum, farklı modellerin aynı görevin farklı alt bileşenlerinde öne çıkabildiğini düşündürmekte; tek bir metriğe dayalı model seçiminin yanıltıcı olabileceğine dikkat çekmektedir.

Açıklama kalitesi değerlendirmesinde de Claude 3.75/5 ile diğer modelleri geride bırakmıştır. Açık kaynak modellerin saldırıyı doğru tespit ettiğinde bile yanlış teknikler öne sürebildikleri görülmüştür. Bu bulgu, modellerin sayısal örüntüleri tanıyabildiğini ancak ATT&CK sınıflandırmasını tam anlamıyla kavrayamadığını düşündürmektedir.

Kategori bazlı analiz ise model performanslarının saldırı türüne göre önemli ölçüde değiştiğini ortaya koymaktadır. Llama+RAG PortScan kategorisinde %85 ile Claude'u (%62) geride bırakırken Mistral+RAG FTP-Patator'da %98 başarıya ulaşmaktadır. Bu durum, RAG sisteminin belirli kategorilerde kapalı kaynak modellerin dezavantajlarını telafi edebildiğine işaret etmektedir. Öte yandan Mistral+RAG'ın SSH-Patator'da yalnızca %5 başarı elde etmesi, bilgi tabanının bu saldırı türünü yeterince kapsamamasından kaynaklanıyor olabilir. Base modellerin BENIGN kategorisinde %100 başarı göstermesi ise yanıltıcıdır; bu modeller her örneği zararsız etiketlediğinden saldırı kategorilerinde %0'a düşmektedir.

## **5.2 RAG'ın Katkısı ve Sınırlılıkları**

RAG sistemi her iki modelde de saldırı tespit doğruluğunu anlamlı biçimde artırmıştır. Öte yandan tactic ve technique doğruluğuna katkısı sınırlı kalmıştır. Bu durum RAG'ın saldırı varlığını tespit etmeye katkı sağladığını, ancak kesin ATT&CK eşleştirmesi için tek başına yeterli olmadığını düşündürmektedir.

## **5.3 Tactic ve Technique Doğruluğunun Düşüklüğü**

Tüm modellerde tactic accuracy'nin düşük kalması iki temel kaynaktan beslenmektedir. Birincisi, modeller saldırıyı tespit edemediğinde tactic alanını N/A olarak döndürmektedir. İkincisi, modeller tactic adını tam olarak doğru yazamamaktadır. Exact match yerine anlamsal benzerlik tabanlı bir değerlendirme metriği bu sorunu kısmen giderebilir.

## **5.4 Hangi Koşulda Hangi Model?**

Yüksek doğruluk öncelikliyse Claude Sonnet 4.5 tercih edilmelidir. Hız öncelikliyse GPT-5.4-mini cazip bir seçenek sunmaktadır. Maliyet kritikse Mistral 7B + RAG sıfır işletim maliyetiyle makul bir performans sağlamaktadır.

## 5.5 Fine-Tuning'in Etkisi

Alan odaklı fine-tuning, Llama 3.2'nin attack detection doğruluğunu %11'den %89'a, tactic accuracy'yi ise %0'dan %89'a yükseltmiştir. Bu sonuç, LoRA gibi parametre verimli ince ayar yöntemlerinin küçük modelleri siber güvenlik görevleri için hızla uzmanlaştırabileceğini göstermektedir.

Bununla birlikte, fine-tuned modelin BENIGN sınıfında 0/10 başarı elde etmesi dikkat çekicidir. Eğitim verisindeki sınıf dengesizliği ve eğitim ile test setinin aynı veri kaynağından türetilmiş olması, bu sonucun yorumlanmasında göz önünde bulundurulması gereken kısıtlamalardır. Gerçek dünya SOC ortamlarında benign trafik oranı çok daha yüksek olduğundan, bu sınıftaki başarısızlık kritik bir eksiklik olarak değerlendirilmelidir.

RAG ile karşılaştırıldığında fine-tuning, tactic ve technique doğruluğu açısından belirgin biçimde üstün sonuçlar vermiştir. RAG saldırı varlığını tespit etmeye katkı sağlarken, fine-tuning modele ATT&CK çerçevesini doğrudan öğretmiş ve yapılandırılmış çıktı kalitesini önemli ölçüde artırmıştır.

## 5.6 Kısıtlamalar

Benchmark tek bir veri kaynağından türetilmiştir; farklı ağ ortamlarındaki genellenebilirlik test edilmemiştir. Yerel modeller tüketici donanımında çalıştırıldığından, daha güçlü bir altyapıdaki sonuçların farklılık gösterebileceği göz önünde bulundurulmalıdır.

---

## 6. Sonuç ve Gelecek Çalışmalar

Bu çalışmada altı LLM konfigürasyonu, Splunk tabanlı bir ön işleme pipeline'ı üzerinde ağ trafiği anomali tespiti ve MITRE ATT&CK eşleştirmesi görevlerinde karşılaştırmalı olarak değerlendirilmiştir. Üç temel bulgu öne çıkmaktadır.

İlk olarak, kapalı kaynak modeller bu görevde açık kaynak alternatiflere kıyasla belirgin biçimde üstün performans sergilemektedir. İkinci olarak, RAG sistemi açık kaynak modellerde belirleyici bir iyileşme sağlamıştır. Üçüncü olarak, tüm modellerde tactic ve technique doğruluğunun düşük kaldığı görülmüştür.

Ek olarak, LoRA ile uygulanan fine-tuning Llama 3.2'nin attack detection doğruluğunu %11'den %89'a yükseltmiş; tactic ve technique doğruluğunu sırasıyla %89 ve %78'e taşımıştır. Bu sonuç, parametre verimli ince ayar yöntemlerinin açık kaynak modelleri siber güvenlik görevleri için etkin biçimde uzmanlaştırabileceğine işaret etmektedir.

Gelecek çalışmalar için alan odaklı fine-tuning, anlamsal benzerlik tabanlı değerlendirme metrikleri ve farklı veri setleriyle genellenebilirlik testleri önerilmektedir.

---

Proje kodu ve benchmark veri seti şu adreste kamuya açık olarak paylaşılmıştır: [github.com/merveguman/BGK601-LLM-Benchmark](https://github.com/merveguman/BGK601-LLM-Benchmark)

## Kaynakça

- [1] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, “Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization,” in *Proc. 4th Int. Conf. Inf. Syst. Security Privacy (ICISSP)*, 2018, pp. 108–116.
- [2] MITRE Corporation, “MITRE ATT&CK Enterprise Framework,” 2024. [Online]. Available: <https://attack.mitre.org>
- [3] T. Hans, R. Beltz, and B. Brinkmann, “Security Logs to ATT&CK Insights: Leveraging LLMs for High-Level Threat Understanding and Cognitive Trait Inference,” *arXiv preprint arXiv:2510.20930*, 2025.
- [4] T. T. Nguyen, T. H. Nguyen, and T. N. Nguyen, “Towards Effective Identification of Attack Techniques in Cyber Threat Intelligence Reports with Large Language Models,” in *Proc. ACM Web Conf. (WWW)*, 2025.
- [5] A. Høst, P. Lison, and L. Moonen, “A Systematic Approach to Predict the Impact of Cybersecurity Vulnerabilities Using LLMs,” *arXiv preprint arXiv:2508.18439*, 2025.
- [6] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [7] A. Borah, M. T. Alam, and N. Rastogi, “Adapting Large Language Models to Emerging Cybersecurity using Retrieval Augmented Generation,” *arXiv preprint arXiv:2510.27080*, 2025.
- [8] M. N. B. Islam and S. Saha, “From Detection to Response: A Deep Learning and Retrieval-Augmented Generation Framework for Network Intrusion Mitigation,” *arXiv preprint arXiv:2605.17960*, 2026.
- [9] F. Blefari, C. Cosentino, F. A. Pironti, A. Furfaro, and F. Marozzo, “CyberRAG: An Agentic RAG Cyber Attack Classification and Reporting Tool,” *arXiv preprint arXiv:2507.02424*, 2025.
- [10] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proc. 2019 Conf. Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, 2019, pp. 3982–3992.
- [11] M. M. Yamin, E. Hashmi, M. Ullah, and B. Katt, “MITRE ATT&CK Applications in Cybersecurity and The Way Forward,” *arXiv preprint arXiv:2502.10825*, 2025.
- [12] H. Touvron, L. Martin, K. Stone et al., “Llama 2: Open Foundation and Fine-Tuned Chat Models,” *arXiv preprint arXiv:2307.09288*, 2023.

- [13] A. Q. Jiang, A. Sablayrolles, A. Mensch et al., “Mistral 7B,” *arXiv preprint arXiv:2310.06825*, 2023.
- [14] OpenAI, “GPT-4 Technical Report,” *arXiv preprint arXiv:2303.08774*, 2023.
- [15] Splunk Inc., “Splunk Enterprise,” 2024. [Online]. Available: <https://www.splunk.com>
- [16] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2022. arXiv preprint arXiv:2106.09685.
- 

## Ekler

### Ek A — Benchmark Örneği

```
{
  "id": 1,
  "kategori": "PortScan",
  "zorluk": "easy",
  "girdi": {
    "Destination Port": 84.0,
    "Flow Duration": 44.0,
    "Total Fwd Packets": 1.0,
    "SYN Flag Count": 0.0,
    "Flow Bytes/s": 136363.6
  },
  "beklenen_cevap": {
    "attack_detected": true,
    "mitre_tactic": "Discovery",
    "mitre_technique_id": "T1046",
    "mitre_technique_name": "Network Service Discovery"
  }
}
```

### Ek B — Prompt Şablonu

**System:** You are a SOC analyst. Analyze the given network traffic flow statistics. Respond ONLY with this JSON format, nothing else: {"attack\_detected": true/false, "mitre\_tactic": "...", "mitre\_technique\_id": "T...", "mitre\_technique\_name": "...",



“severity”: “Low/Medium/High/Critical”, “explanation”: “brief explanation”}

**User:** Analyze the following network traffic flow statistics: Destination Port: [X] Flow Duration: [X] Total Fwd Packets: [X] ...

## Ek C — Yapay Zeka Araçları Kullanım Notu

| Araç                      | Kullanım Amacı                             | Aşama        |
|---------------------------|--------------------------------------------|--------------|
| Claude API<br>(Anthropic) | Kapalı kaynak model değerlendirmesi        | Deney        |
| GPT-5.4-mini<br>(OpenAI)  | Kapalı kaynak model değerlendirmesi        | Deney        |
| Ollama + Llama 3.2        | Açık kaynak model değerlendirmesi          | Deney        |
| Ollama + Mistral<br>7B    | Açık kaynak model değerlendirmesi          | Deney        |
| Claude (claude.ai)        | Proje planlaması ve kod geliştirme desteği | Tüm aşamalar |

Tüm benchmark anotasyonları araştırmacı tarafından elle gerçekleştirilmiştir. YZ araçlarının ürettiği çıktılar eleştirel bir perspektifle değerlendirilmiş; olası hatalardan araştırmacı sorumludur.